

# Estimación de la Curva de Phillips para Finlandia

JM Artiles

## CASO DE FINLANDIA



### 0. Introducción y comprobaciones previas

El objetivo es contrastar si existe un tradeoff entre inflación (inf) y desempleo (des). Esto se realiza mediante:

- La estimación de la **curva de Phillips estática** .
- La estimación de la **curva de Phillips dinámica** (con retardos).
- Contrastes de **cambio estructural** (Chow) y otros supuestos clásicos (autocorrelación, heteroscedasticidad, etc.).

Realizaremos el trabajo con el país de **Finlandia**, teniendo en cuenta ciertas peculiaridades de la serie de datos que tendremos como fuente.

### 1. Librerías Generales

Carga de librerías para usar en este proyecto

```
#install.packages( "WDI")
#install.packages( "DT")
#install.packages( "ggplot2")
#install.packages( "ggfortify")
#install.packages( "urca")
#install.packages( "fUnitRoots")
#install.packages( "lmtest")
#install.packages("car")
#install.packages("strucchange")
#install.packages("dynlm")
```

```
library("WDI")
library("DT")
library("ggplot2")
library("ggfortify")
library("urca")
library("fUnitRoots")
```

```
Adjuntando el paquete: 'fUnitRoots'
```

```
The following objects are masked from 'package:urca':
```

```
punitroot, qunitroot, unitrootTable
```

```
library("lmtest")
```

```
Cargando paquete requerido: zoo
```

```
Adjuntando el paquete: 'zoo'
```

```
The following objects are masked from 'package:base':
```

```
as.Date, as.Date.numeric
```

```
library("car")
```

```
Cargando paquete requerido: carData
```

```
library("strucchange")
```

Cargando paquete requerido: sandwich

```
library("dynlm")
```

## 2. Descarga de datos para Finlandia de Inflación y Desempleo.

Seleccionamos datos de inflación y desempleo de Finlandia.

```
# Obtener datos de inflación y desempleo para Finlandia (1960-2023) data_FIN <- WDI(indicator = c("desempleo" = "SL.UEM.TOTL.NE.ZS",  
                                "inflacion" = "FP.CPI.TOTL.ZG"),  
                                country = "FIN", start = 1960, end = 2023)  
  
# Para ver las primeras filas de los datos  
head(data_FIN)  
  country iso2c iso3c year desempleo inflacion  
1 Finland FI FIN 1960 NA  
                           3.418127  
2 Finland FI FIN 1961 NA  
                           1.691002  
3 Finland FI FIN 1962 NA  
                           4.383983  
4 Finland FI FIN 1963 NA  
                           4.996382  
5 Finland FI FIN 1964 NA  
                           10.275861  
6 Finland FI FIN 1965 NA  
                           4.940588
```

## 3. Preparación de los datos

Observamos que en los datos del banco mundial la serie de desempleo para Finlandia empieza a contabilizarse en otro año.

```
# Verificar si hay valores NA en la columna de desempleo  
sum(is.na(data_FIN[, 1]))  
[1] 0
```

```
# Eliminar filas con valores faltantes data_FIN_clean <-
```

```
na.omit(data_FIN) # Verificar que  
no quedan NAs  
sum(is.na(data_FIN_clean))
```

```
[1] 0
```

Ahora, filtramos el dataframe a partir del año 1969 y convertimos los datos en serie temporal

```
# Convertir los datos en formato de serie temporal (desde 1969)  
data_FIN_clean <- ts(data_FIN_clean[, c("desempleo",  
"inflacion")],  
                        start = c(1969), end = c(2023), frequency = 1)
```

```
# Para ver las primeras filas de los datos
```

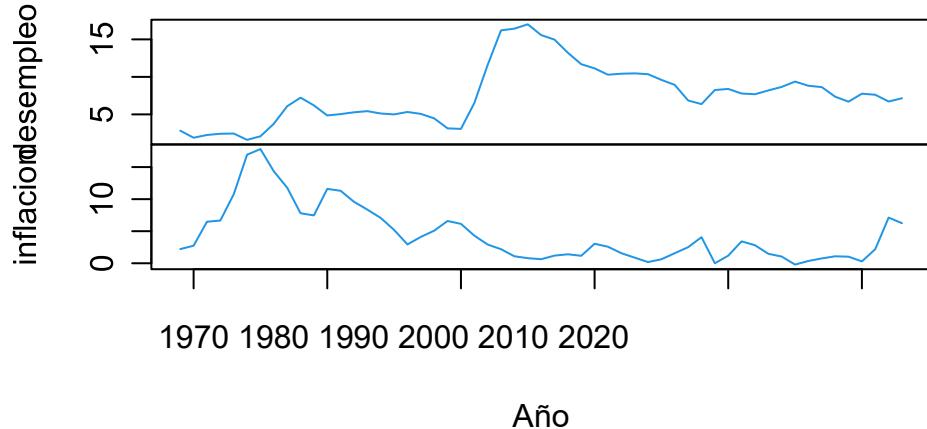
```
head(data_FIN_clean)  
desempleo inflacion  
[1,] 2.83  
      2.205611  
[2,] 1.89  
      2.740420  
[3,] 2.26  
      6.475765  
[4,] 2.42  
      6.662498  
[5,] 2.45  
      10.754472  
[6,] 1.61  
      16.936400
```

#### 4. Representación gráfica de las series temporales

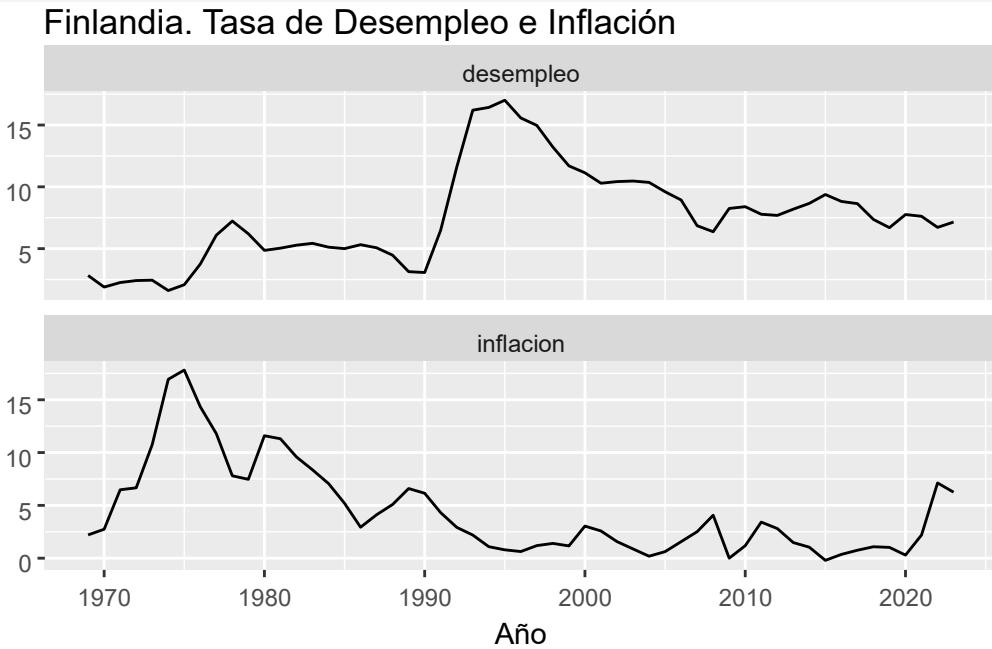
```
# Gráfico con la función "plot"
```

```
plot(data_FIN_clean, col = 4, xlab = "Año", main = "Finlandia. Tasa de Desempleo  
e Inflación")
```

## Finlandia. Tasa de Desempleo e Inflación



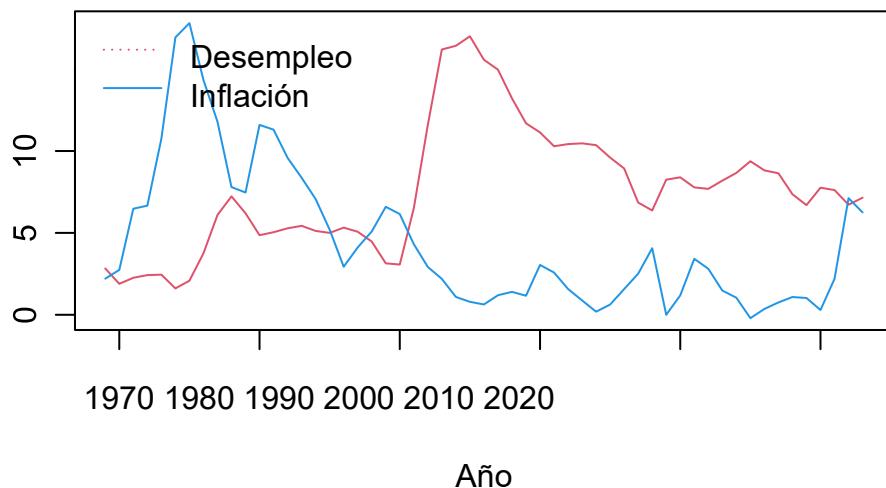
```
# Gráfico con la función "autoplot"  
autoplot(data_FIN_clean, facets = TRUE) +  
xlab("Año") + ylab("") +  
ggtitle("Finlandia. Tasa de Desempleo e Inflación")
```



```
# Representación conjunta con "ts.plot"
ts.plot(data_FIN_clean[, 1], data_FIN_clean[, 2], col = c(2, 4),
         gpars = list(xlab = "Año", ylab = ""),
         main = "Finlandia. Tasas de Desempleo e Inflación")
legend("topleft", legend = c("Desempleo", "Inflación"), col =
c(2, 4), lty = c(3, 1), bty = "n")
```

15 –

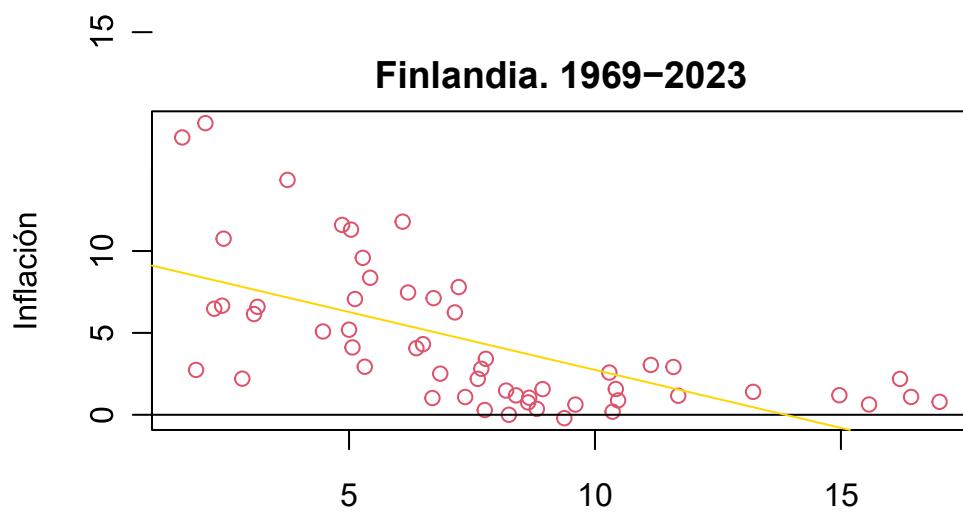
### Finlandia. Tasas de Desempleo e Inflación



## 5. Diagrama de dispersión

El periodo de análisis incluye el periodo de “gran inflación de los años 70” en el caso finlandés tenemos datos entre 1969 y 1982, aparentemente este país no fue tan golpeado como los Estados Unidos por la crisis del petroleo. Vemos el diagrama de dispersión:

```
# Diagrama de dispersión Inflación-Desempleo  
(1969-2023) y <- as.vector(data_FIN_clean[, 2])  
# Inflación x <- as.vector(data_FIN_clean[, 1])  
# Desempleo plot(x, y, main = "Finlandia. 1969-  
2023", col = 2, xlab = "Desempleo", ylab =  
"Inflación") +  
abline(h = 0, col = "black") +  
abline(lm(y ~ x), col = "gold")
```



15 –

```
# Diagrama de dispersión para 1969-1982
# Diagrama de dispersión Inflación-Desempleo
(1969-1982) y <- as.vector(data_FIN.1[, 2]) #
Inflación x <- as.vector(data_FIN.1[, 1]) #
Desempleo plot(x, y, main = "Finlandia. 1969-
1982", col = 2, xlab = "Desempleo", ylab =
"Inflación") +
```

15 -

```
abline(h = 0, col = "black") +
abline(lm(y ~ x), col = "green")
```

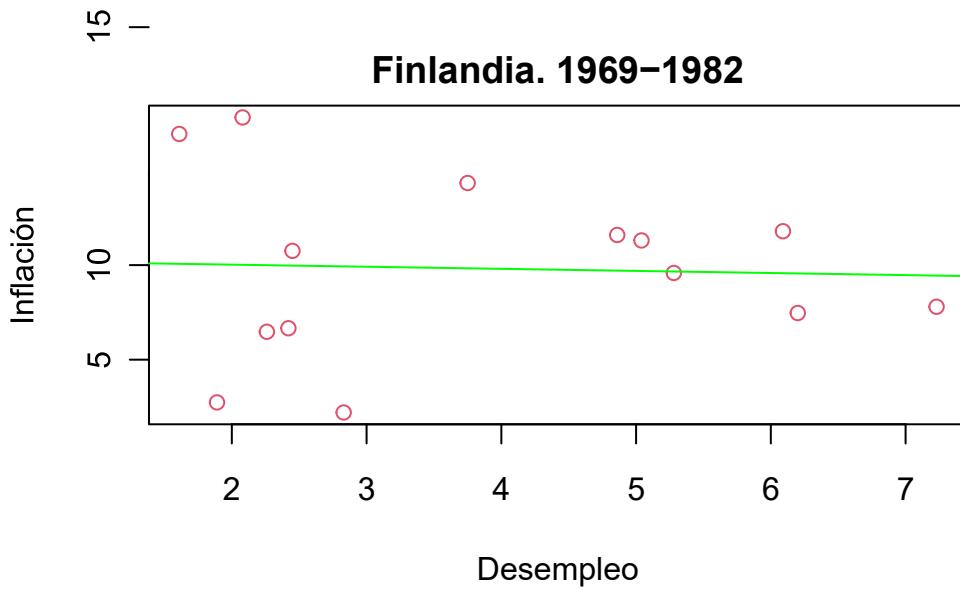
## Desempleo

```
integer(0)
```

Con la representación gráfica, al igual que el caso norteamericano, no podemos saber si existe *trade-off* claro entre desempleo e inflación. Analizamos las submuestras, siendo la primera más corta que el caso norteamericano.

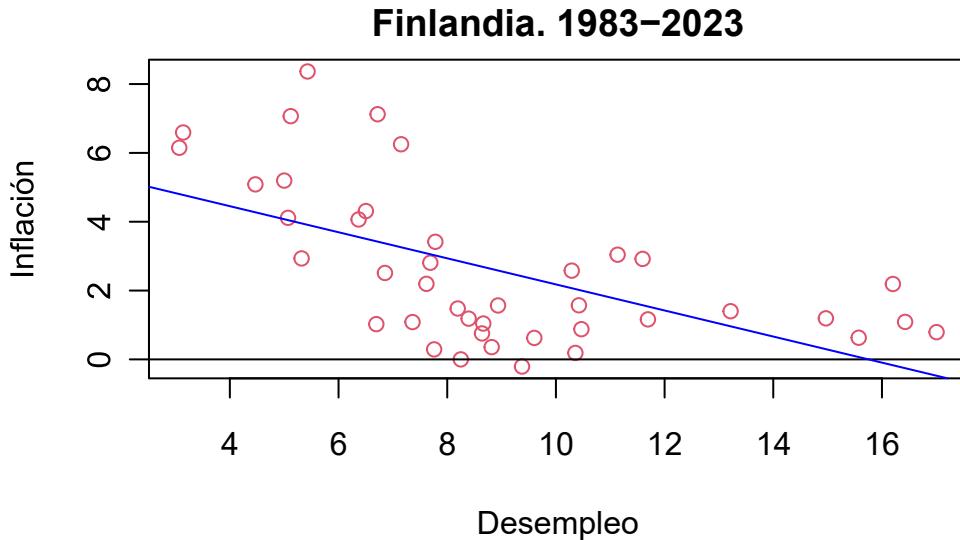
```
# Submuestra 1969-1982 (periodo de Gran Inflación)
data_FIN.1 <- window(data_FIN_clean, frequency = 1, start =
c(1969), end = c(
  # Submuestra 1983-2023 (periodo de menor inflación)
  data_FIN.2 <- window(data_FIN_clean, frequency = 1, start =
  c(1983), end = c(
    1982))
```

2023))



```
integer(0)

# Diagrama de dispersión para
1983-2023 y <-
as.vector(data_FIN.2[, 2]) x <-
as.vector(data_FIN.2[, 1])
plot(x, y, main = "Finlandia. 1983-2023", col
= 2, xlab = "Desempleo", ylab =
"Inflación") +
abline(h = 0, col = "black") +
abline(lm(y ~ x), col = "blue")
```



```
integer(0)
```

Vemos claramente que existe una relación de *trade-off* entre inflación y desempleo, a partir de 1983. Anteriormente parece que tambien, pero la pendiente es casi imperceptible.

## 6. Estimación de la curva de Phillips para Finlandia

Verificamos el *tradeoff* entre inflación ( $inf_t$ ) y desempleo ( $des_t$ ). Estimamos por MCO la curva de Phillips estática, y la curva de Phillips aumentada con expectativas. Contrastamos la estacionariedad de las variables. Si las variables no son estacionarias la estimación MCO es sesgada e inconsistente y los estadísticos de contraste habituales no serán válidos.

Aplicamos el contraste de raíz unitaria de Dickey Fuller Aumentado (ADF). Para el desempleo el contraste de ADF con la *ecuación con constante*. La inflación sí muestra una tendencia durante la primera parte de la muestra por lo que se escoge la *ecuación con constante y con tendencia*. Se consideran 10 retardos al igual que en el caso norteamericano.

```
# Contraste de estacionariedad (raíz unitaria) para el desempleo
# (1960-2023) summary(ur.df(y = data_FIN_clean[, 1], lags = 10, type =
# "drift", selectlags =
# "BIC")) )
```

```

#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression drift

Call: lm(formula = z.diff ~ z.lag.1 + 1
+ z.diff.lag)

Residuals:
    Min      1Q  Median      3Q     Max 
-1.75727 -0.88831 -0.04573  0.53483  2.69061 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 1.21314   0.43726   2.774 0.00829 **  
z.lag.1     -0.13797   0.04727  -2.919 0.00568 **  
z.diff.lag  0.65228   0.11718   5.567 1.79e-06 ***  
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' '
1

Residual standard error: 1.078 on 41 degrees of freedom
Multiple R-squared: 0.4554, Adjusted R-squared: 0.4288 
F-statistic: 17.14 on 2 and 41 DF, p-value: 3.894e-06

```

Value of test-statistic is: -2.9188 4.2749

Critical values for test statistics:

	1pct	5pct
10pct	tau2	-3.51
2.89	-2.58	phi1
4.71	3.86	6.70

Resultados del contraste de estacionariedad para el desempleo:

- En base al criterio BIC se ha seleccionado 1 retardo.
- El estadístico de DFA (tau2) es igual a -3.51.
- Se rechaza la nula de raíz unitaria al 5% y por tanto la serie es estacionaria ( $I(0)$  con media constante)

```

# Contraste de raíz unitaria para la inflación (1969-2023)
summary(ur.df(y = data_FIN_clean[, 2], lags = 10, type = "trend",
selectlags =
                                "BIC"))

#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression trend

Call: lm(formula = z.diff ~ z.lag.1 + 1 + tt
+ z.diff.lag)

Residuals:
    Min      1Q  Median      3Q     Max 
-3.8634 -0.7747 -0.1996  0.2876  4.1310 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 0.191422  1.332176  0.144   0.8865    
z.lag.1     -0.135297  0.124025 -1.091   0.2820    
tt          0.004204  0.029595  0.142   0.8878    
z.diff.lag1 0.215677  0.170862  1.262   0.2143    
z.diff.lag2 -          0.164774 -2.234   0.0313    
0.368113               *                        
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' '
1

Residual standard error: 1.487 on 39 degrees of freedom
Multiple R-squared: 0.2231, Adjusted R-squared: 0.1434
F-statistic: 2.8 on 4 and 39 DF, p-value: 0.03895

Value of test-statistic is: -1.0909 1.3468 1.8994

Critical values for test statistics:
      1pct      5pct
10pct tau3 -4.04 - 

```

```

3.45 -3.15 phi2 6.50
4.88 4.16 phi3 8.73
6.49 5.47

```

Resultados del contraste de estacionariedad para la inflación:

- En base al criterio BIC se ha seleccionado 1 retardo.
- El estadístico de DFA ( $\tau_3$ ) es igual a -4.04
- La tendencia incluida en la ecuación es significativa, por tanto la serie es estacionaria alrededor de una tendencia  $I(0)$  con tendencia

Ahora hacemos el contraste con el paquete **fUnitsRoots**, consideramos 1 retardo (lags=1), que es el número de retardos seleccionado por la función *ur.df* antes, para la inflación y para el desempleo.

```

# Desempleo (1960-2023)
# Con la función "unitrootTest" (valores críticos de MacKinnon
# (1996)) unitrootTest(data_FIN_clean[,1], lags = 1, type = c("c"))

```

Title:  
Augmented Dickey-Fuller Test

Test Results:

PARAMETER:

Lag Order: 1

STATISTIC:

DF: -

2.9929 P

VALUE: t:

0.0419 n:

0.6484

Description:

Mon Apr 21 15:25:08 2025 by user: JM

```
# Alternativamente, con la función "adfTest" (valores críticos de Dickey Fuller)
adfTest(data_FIN_clean[,1], lags = 1, type = c("c"))
```

Title:

Augmented Dickey-Fuller Test

Test Results:

PARAMETER:

Lag Order: 1

STATISTIC:

Dickey-Fuller: -

2.9929 P VALUE:

0.04428

Description:

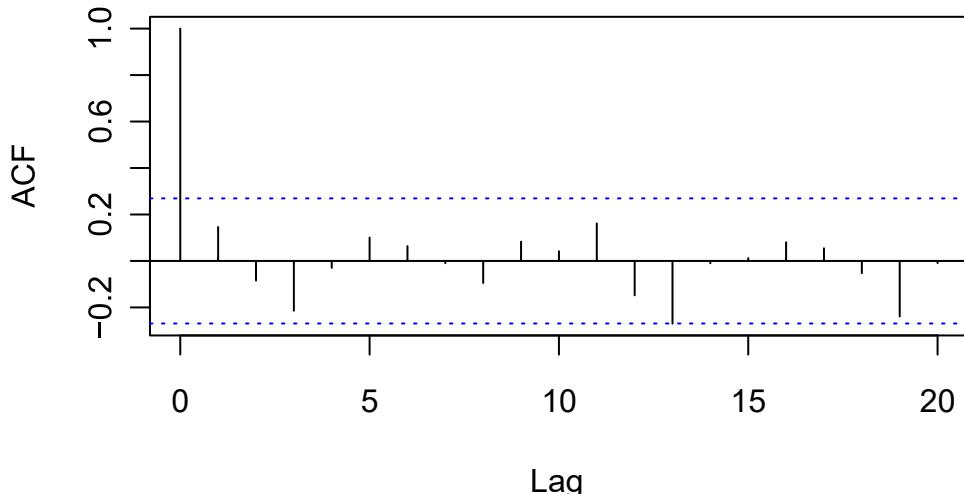
Mon Apr 21 15:25:08 2025 by user: JM

```
# Le damos nombre y creamos un objeto con la información del  
contraste.
```

```
DF_des<-adfTest(data_FIN_clean[,1], lags = 1, type = c("c"))
```

```
    #Para comprobar que los residuos de la ecuación de DFA son un :  
vemos el correlogram acf(DF_des@test$lm$residuals, lag.max = 20, main :  
Autocorre
```

### Función de Autocorrelación (ACF)



El resultado del contraste indica que el estadístico de DFA es igual a

-2.9929 con

un p-valor

0.0419

(valores críticos MacKinnon, 1996). Se rechaza la hipótesis nula de raíz unitaria al 5%.

Realizamos los cálculos para la inflación:

```
# Inflación (1960-2023)
# Con "unitrootTest" (valores críticos de MacKinnon (1996))
unitrootTest(data_FIN_clean[,2], lags = 1, type = c("ct"))
```

Title:

Augmented Dickey-Fuller Test

Test Results:

PARAMETER:

Lag Order: 1

STATISTIC:

DF: -3.7043

P VALUE: t:

0.03049 n:

0.8971

Description:

Mon Apr 21 15:25:09 2025 by user: JM

```
# Con "adfTest" (valores críticos de Dickey Fuller)
adfTest(data_FIN_clean[,2], lags = 1, type = c("ct"))
```

Title:

Augmented Dickey-Fuller Test

Test Results:

PARAMETER:

Lag Order: 1

STATISTIC:

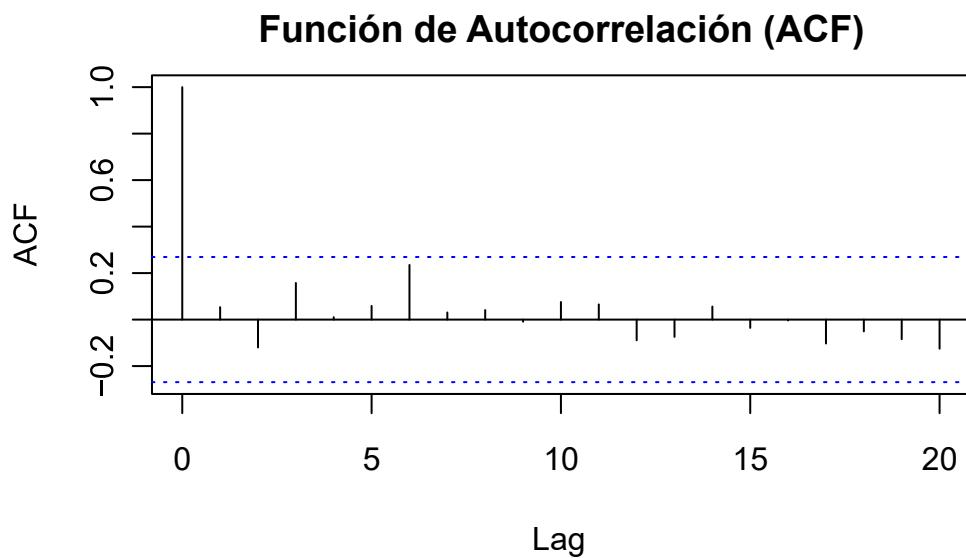
Dickey-Fuller: -

3.7043 P VALUE:

0.03255

Description:  
Mon Apr 21 15:25:09 2025 by user: JM

```
# Le damos nombre y creamos un objeto con la información del  
contraste.  
DF_inf<-adfTest(data_FIN_clean[,2], lags = 1, type = c("ct"))  
  
#Para comprobar que los residuos son un ruido blanco, vemos el corr  
los residuos acf(DF_inf@test$lm$residuals, lag.max = 20, main = '  
Autocorrelación (ACF)')
```



El resultado del contraste indica que el estadístico de DFA es igual a

-3.7043

, con un p-valor

0.03049

(valores críticos MacKinnon, 1996). Se rechaza la hipótesis nula de raíz unitaria al 5%.

Comprobamos con los contrastes de raíz unitaria que las series de inflación y desempleo son I(0), por lo que se pueden incluir en niveles en una regresión MCO.

## 7. Estimación de la Curva de Phillips estática

La curva de Phillips estática viene dada por la siguiente ecuación:

$$inf_t = \beta_0 + \beta_1 des_t + \epsilon_t$$

Aplicamos según lo visto en el caso de los Estados Unidos, la curva de Phillips supone una tasa natural de desempleo constante y expectativas de inflación constantes, y se utiliza para estudiar la relación contemporánea entre la inflación y el desempleo. Si hay *tradeoff* entre inflación y desempleo entonces  $\beta_1 < 0$ .

```
# Renombrar las columnas para facilitar
colnames(data_FIN_clean) <- c("des", "inf")
colnames(data_FIN.1) <- c("des", "inf")
colnames(data_FIN.2) <- c("des", "inf")
```

*7.1. Estimación del modelo* Estimamos el modelo para toda la serie temporal  $inf_t = \beta_0 + \beta_1 des_t + \epsilon_t$  (1969-2023). Para ello, se utiliza la función *lm*.

```
# Estimar el modelo para la muestra completa (1969-
2023) modelo1 <- lm(inf ~ des, data = data_FIN_clean)
summary(modelo1)
```

```
Call: lm(formula = inf ~ des, data =
data_FIN_clean)

Residuals:
    Min      1Q  Median      3Q     Max 
-5.7363 -2.4249 -0.9994  2.0517  9.4691 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 9.8140     1.0304    9.525 4.49e-13 ***
des        -0.7076     0.1212   -5.837 3.29e-07 ***  
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' '
1

Residual standard error: 3.443 on 53 degrees of freedom
```

Multiple R-squared: 0.3913, Adjusted R-squared: 0.3798  
 F-statistic: 34.07 on 1 and 53 DF, p-value: 3.29e-07  
 El resultado si nos muestra *tradeoff* entre inflación y desempleo:  $\beta_1 < 0$ . El p-valor del estadístico t para  $\beta_1$  es -0.37888 si existe relación entre desempleo e inflación.

El periodo de análisis incluye el periodo de “Gran Inflación” de los años 70, analizando las submuestras por separado comprobamos si la relación entre inflación y desempleo cambia después de este periodo inflacionista, estimamos la ecuación por separado para cada una de las dos submuestras: (1960-1982) y (1983-2023).

Estimamos la curva de Phillips estática para la primera submuestra (1960-1982).

```
# Estimar el modelo para la submuestra de 1960-1982
modelo1.1 <- lm(inf ~ des, data = data_FIN.1)
summary(modelo1.1)
```

```
Call: lm(formula = inf ~ des, data =
data_FIN.1)
```

Residuals:

Min	1Q	Median	3Q	Max
-7.7274	-3.0103	0.3511	2.1369	7.7955

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	10.2458	3.0530	3.356	0.00572 **
des	-0.1105	0.7164	-0.154	0.87998
---				
Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'
1				

Residual standard error: 4.86 on 12 degrees of freedom  
 Multiple R-squared: 0.001979, Adjusted R-squared: -0.08119  
 F-statistic: 0.02379 on 1 and 12 DF, p-value: 0.88

Ahora estimamos a segunda submuestra (1983-2023)

```
# Estimar el modelo para la submuestra de 1983-2023
modelo1.2 <- lm(inf ~ des, data = data_FIN.2)
summary(modelo1.2)
```

Call:

```
lm(formula = inf ~ des, data = data_FIN.2)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.8419	-1.6032	0.0664	1.2664	4.4560

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	5.96758	0.79077	7.547	3.85e-09
*** des	-0.37888	0.08303	-4.563	4.91e-05
***				
---				
Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'
	1			

Residual standard error: 1.855 on 39 degrees of freedom

Multiple R-squared: 0.3481, Adjusted R-squared: 0.3314

F-statistic: 20.82 on 1 and 39 DF, p-value: 4.914e-05

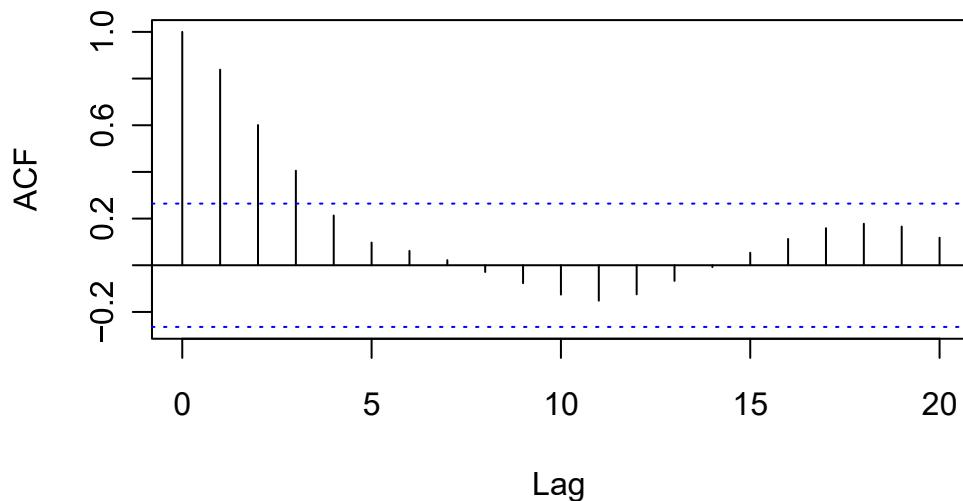
Los resultados de las estimaciones por submuestras confirman el *trade-off*. Para la primera submuestra  $\hat{\beta}_1$  es negativa y significativa al 10%, igual para el periodo (1983-2023)  $\hat{\beta}_1$ , mostrando un *trade-off* entre inflación y desempleo.

### 7.2. Contrastes de autocorrelación.

Comprobamos la existencia de problemas de autocorrelación, los cuales son habituales en modelos estáticos.

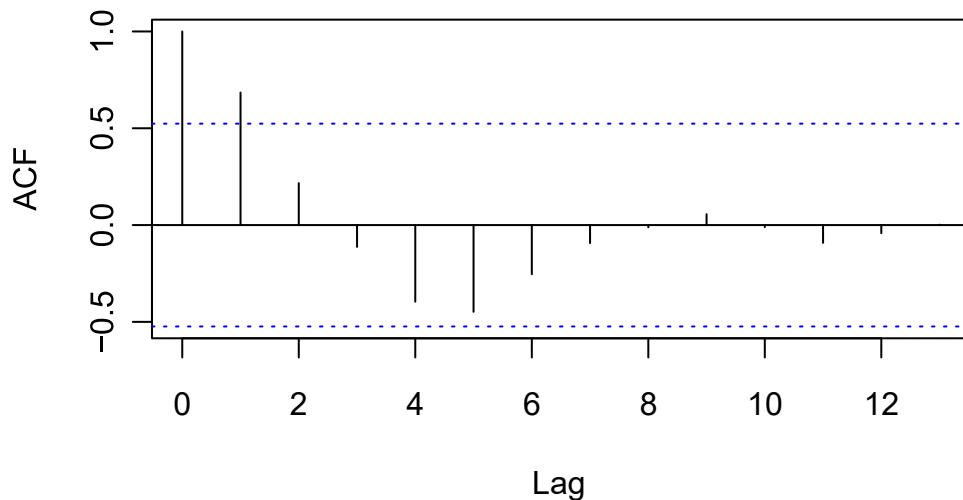
```
# Función de autocorrelación para toda la muestra
acf(modelo1$residuals, lag.max = 20, main = "Función de Autocorrelación
(1969-2023)")
```

### Función de Autocorrelación (1969–2023)

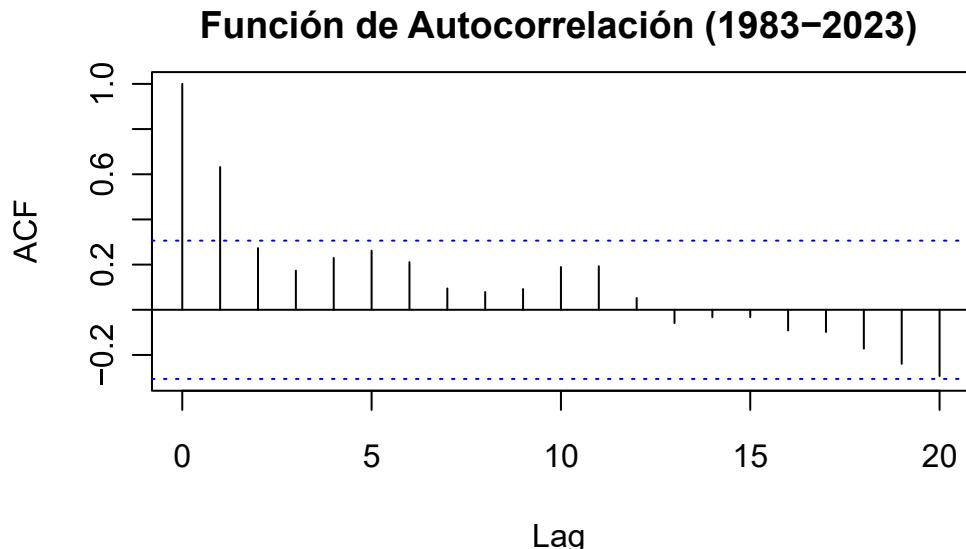


```
# La función de autocorrelación de los residuos del modelo (1969–1982)
#                                         )
acf(modelo1.1$residuals, lag.max = 20, main = "Función de Autocorrelación (1969–1982)")
```

### Función de Autocorrelación (1969–1982)



```
# La función de autocorrelación de los residuos del modelo (1983–2023)
#                                         )
acf(modelo1.2$residuals, lag.max = 20, main = "Función de Autocorrelación (1983–2023)")
```



Como era de esperar, en los tres escenarios vemos que existe autocorrelación en el período 0. En segundo lugar, aplicamos el contraste de Durbin-Watson (DW) a los residuos de las tres ecuaciones estimadas.

```
#Contraste de Durbin-Watson (1969–2023)
dwtest(modelo1, alternative = "two.sided", iterations =
1000)
```

Durbin-Watson test

```
data: modelo1
DW = 0.27035, p-value < 2.2e-16
alternative hypothesis: true autocorrelation is not 0
```

```
#Contraste de Durbin-Watson (1960–1982)
dwtest(modelo1.1, alternative = "two.sided", iterations = 1000)
```

Durbin-Watson test

```
data: modelo1.1
DW = 0.42042, p-value = 1.255e-05
```

```
alternative hypothesis: true autocorrelation is not 0
```

```
#Contraste de Durbin-Watson (1983-2023)
dwtest(modelo1.2, alternative ="two.sided", iterations =
1000)
```

```
Durbin-Watson test
```

```
data: modelo1.2
DW = 0.5217, p-value = 4.134e-09 alternative
hypothesis: true autocorrelation is not 0
```

En todos los casos se rechaza la hipótesis nula de no autocorrelación, por lo que **hay evidencia de correlación serial de primer orden**. Ahora, aplicamos el contraste de autocorrelación de Breusch-Godfrey (BG) en las tres ecuaciones estimadas.

```
# Contraste de Breusch-Godfrey bgtest(modelo1, order = 1) # para
contrastar autocorrelación de primer orden
```

```
Breusch-Godfrey test for serial correlation of order up
to 1
```

```
data: modelo1
LM test = 38.916, df = 1, p-value = 4.425e-10
```

```
bgtest(modelo1,order = 2) # para contrastar autocorrelación de
segundo orden
```

```
Breusch-Godfrey test for serial correlation of order up
to 2
```

```
data: modelo1
LM test = 40.705, df = 2, p-value = 1.449e-09
```

```

#Contraste de Breusch-Godfrey (1969-1982) bgtest(modelo1.1, order =
1) # para contrastar autocorrelación de primer orden Breusch-
Godfrey test for serial correlation of order up to 1

data: modelo1.1
LM test = 7.3713, df = 1, p-value = 0.006627 bgtest(modelo1.1,order = 2)

# para contrastar autocorrelación de hasta segundo orden

Breusch-Godfrey test for serial correlation of order up
to 2

data: modelo1.1
LM test = 8.3039, df = 2, p-value = 0.01573

#Contraste de Breusch-Godfrey (1983-2023) bgtest(modelo1.2,order =
1) # para contrastar autocorrelación de primer orden

Breusch-Godfrey test for serial correlation of order up
to 1

data: modelo1.2
LM test = 17.739, df = 1, p-value = 2.534e-05 bgtest(modelo1.2,order = 2)

# para contrastar autocorrelación de hasta segundo orden

Breusch-Godfrey test for serial correlation of order up
to 2

data: modelo1.2
LM test = 18.382, df = 2, p-value = 0.0001019

```

Los contrastes de autocorrelación de primer y segundo orden confirman que hay autocorrelación. En los tres casos se rechaza la hipótesis nula de no autocorrelación.

7.3. *Estimación con errores estándar robustos a la autocorrelación (Newey-West)* Newey-West proporciona errores estándar robustos a la autocorrelación y a la heteroscedasticidad, lo que permite obtener estadísticos de contraste válidos.

```
# Para toda la muestra completa (1969-2023)
coefest(modelo1,vcov=NeweyWest(modelo1)) # 1969-2023
```

```
t test of coefficients:
```

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	9.81405	3.89471	2.5198	0.01479 *
des	-0.70757	0.37941	-1.8649	0.06773 .

---

Signif. codes: 0 '\*\*\*\*' 0.001 '\*\*\*' 0.01 '\*\*' 0.05 '\*' 0.1 '.' 1

```
#Estimación con errores estándar robustos a la autocorrelación (Newey-West)
(1960-1982) coefest(modelo1.1,vcov=NeweyWest(modelo1.1)) # 1969-1982
```

```
t test of coefficients:
```

	Estimate	Std. Error	t value
Pr(> t )	(Intercept)	10.24576	6.58174
1.5567	0.1455	des -0.11051	1.14883 -
0.0962	0.9250		

```
#Estimación con errores estándar robustos a la autocorrelación (Newey-West)
(1983-2023) coefest(modelo1.2,vcov=NeweyWest(modelo1.2)) # 1983-2023
```

```
t test of coefficients:
```

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	5.96758	1.38815	4.2989	0.0001109 ***
des	-0.37888	0.14430	-2.6257	0.0122893 *

---

```
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' '
```

1

Los resultados muestran que  $\hat{\beta}_1$  es negativo pero solo es significativo en el modelo estimado para el periodo 1983-2023 pero no podemos garantizar la existencia de *tradeoff* entre inflación y desempleo en la primera submuestra.

## 8. Contraste de cambio estructural

Comprobamos la existencia de un cambio estructural en la relación entre inflación y desempleo, añadiendo variables ficticias aditivas y multiplicativas.

Para estimar el modelo y realizar el contraste hay que generar previamente las variables ficticias, el cúal sería:

$$inf_t = \beta_0 + \beta_1 des_t + \beta_2 f_t + \beta_3 fdes_t + \epsilon_t$$

donde  $f_t$  es una variable dicotómica aditiva de valor 0 hasta 1982 y valor 1 a partir de 1983, y  $fdes_t$  es la variable ficticia multiplicativa:  $fdes_t = f_t * des_t$ .

El contraste de cambio estructural es:

$$\begin{cases} H_0: \beta_2 = \beta_3 = 0 \\ H_1: \text{no } H_0 \end{cases}$$

Para estimar el modelo y realizar el contraste hay que generar previamente las variables ficticias.

```
# Generar variables ficticias (=0 hasta 1982, =1
desde 1983) f <- ifelse(index(data_FIN_clean) >
1982, 1, 0)
fdes <- f * data_FIN_clean[, "des"] #para generar la ficticia
multiplicativa
# Verificar las variables ficticias
summary(f)
```

```
Min. 1st Qu. Median Mean 3rd Qu. Max.
0.0000 0.5000 1.0000 0.7455 1.0000 1.0000
```

```
summary(fdes)
```

```
Min. 1st Qu. Median Mean 3rd Qu. Max.
```

```
0.000 1.534 7.151 6.606 9.489 17.005
```

```
#Estimamos el modelo y lo guardamos en un objeto llamado
modelo2 modelo2 <- lm(inf ~ des + f + fdes, data =
data_FIN_clean) summary(modelo2)
Call: lm(formula = inf ~ des + f + fdes, data =
data_FIN_clean)
```

Residuals:

Min	1Q	Median	3Q	Max
-7.7274	-1.6766	0.0664	1.3446	7.7955

Coefficients:

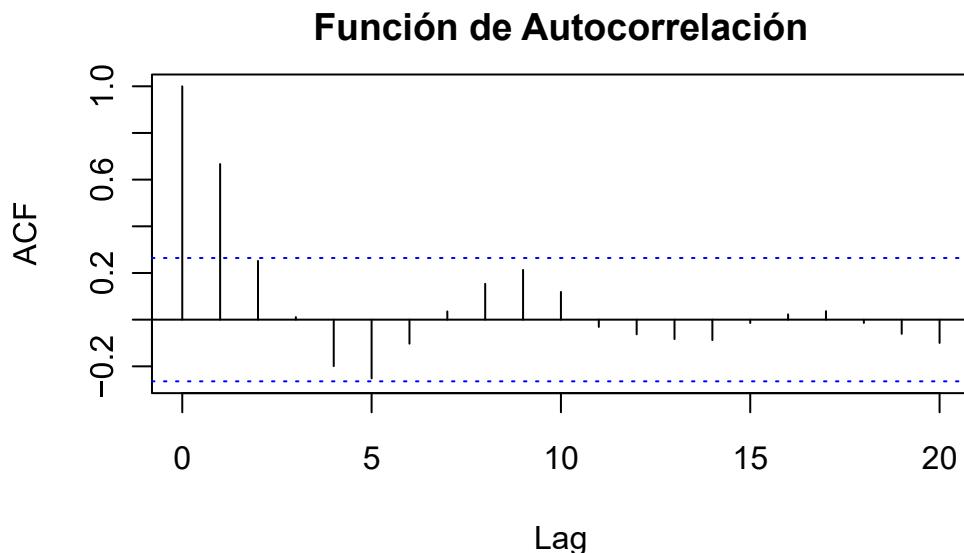
	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	10.2458	1.7977	5.699	6.04e-07
		***		
des	-0.1105	0.4219	-0.262	0.7944
f	-4.2782	2.1725	-1.969	0.0544 .
fdes	-0.2684	0.4409	-0.609	0.5454
---				
Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'
	1			

Residual standard error: 2.862 on 51 degrees of freedom

Multiple R-squared: 0.5954, Adjusted R-squared: 0.5716

F-statistic: 25.02 on 3 and 51 DF, p-value: 4.302e-10

```
# La función de autocorrelación de los residuos del modelo con
ficticias acf(modelo2$residuals, lag.max = 20, main = "Función de
Autocorrelación")
```



El correlograma de los residuos del modelo con ficticias muestra autocorrelación positiva, aplicamos los contrastes de DW y BG.

```
#Contraste de Durbin-Watson. Modelo con ficticias
dwtest(modelo2,alternative ="two.sided",iterations = 1000)
```

Durbin-Watson test

```
data: modelo2
DW = 0.50217, p-value = 8.595e-13
alternative hypothesis: true autocorrelation is not 0
```

```
#Contraste de Durbin-Watson. Modelo con ficticias
dwtest(modelo2,alternative ="two.sided",iterations = 1000)
```

Durbin-Watson test

```
data: modelo2
DW = 0.50217, p-value = 8.595e-13 alternative
hypothesis: true autocorrelation is not 0
```

Los contrastes de autocorrelación rechazan la nula, existe autocorrelación. Por tanto, debemos aplicar el test de Chow corrigiendo las varianzas.

```
# Especificamos el modelo en el que queremos hacer el contraste, la hipótesis nula y el estad linearHypothesis(modelo2, c("f=0","fdes=0"), vcov = NeweyWest(modelo2))
```

```
Linear hypothesis
test: f = 0
fdes = 0

Model 1: restricted model
Model 2: inf ~ des + f + fdes

Note: Coefficient covariance matrix supplied.
```

```
Res.Df Df      F    Pr(>F)
1      53
2      51 2 11.609 6.998e-05 ***
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' '
1
```

Estimación del modelo con ficticias con errores estándar robustos a la autocorrelación (NeweyWest).

```
coeftest(modelo2, vcov=NeweyWest(modelo2)) #
```

t test of coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	10.24576	7.41813	1.3812	0.1732
des	-0.11051	1.28732	-0.08580	0.9319
f	-4.27818	7.62695	-0.56090	0.5773
fdes	-0.26837	1.29849	-0.20670	0.8371

Las ficticias no son significativas, la que coincide con los resultados anteriores, en Finlandia no se reflejo un cambio estructural por la crisis del petróleo.

Para contrastar cambio estructural con la función *sctest*. Procedemos a encontrar la posición de 1983 en el Dataframe para hacer el contraste

```
# Extraer el índice temporal (aplicar en caso de error)
time_index <- time(data_FIN_clean)

# Mostrar el índice temporal junto con los datos
data_with_time <- cbind(time_index, data_FIN_clean)
print(data_with_time)
```

```
Time Series:
Start = 1969
End = 2023
Frequency = 1 time_index data_FIN_clean.des
            data_FIN_clean.inf
1969      1969        2.830    2.205611e+00
1970      1970        1.890    2.740420e+00
1971      1971        2.260    6.475765e+00
1972      1972        2.420    6.662498e+00

1973      1973        2.450    1.075447e+01
1974      1974        1.610    1.693640e+01
1975      1975        2.080    1.781140e+01
1976      1976        3.750    1.434269e+01
1977      1977        6.090    1.179335e+01
1978      1978        7.230    7.799351e+00
1979      1979        6.200    7.466962e+00
1980      1980        4.860    1.159462e+01
1981      1981        5.040    1.130576e+01
1982      1982        5.280    9.584928e+00
1983      1983        5.430    8.366293e+00
1984      1984        5.120    7.067656e+00
1985      1985        5.000    5.195622e+00
1986      1986        5.320    2.933579e+00
1987      1987        5.070    4.113029e+00
1988      1988        4.470    5.085929e+00
1989      1989        3.140    6.592910e+00
1990      1990        3.069    6.149565e+00
1991      1991        6.503    4.310213e+00
1992      1992       11.595    2.919323e+00
1993      1993       16.201    2.190653e+00
```

1994	1994	16.426	1.088557e+00
1995	1995	17.005	7.912394e-01
1996	1996	15.572	6.291942e-01
1997	1997	14.968	1.192559e+00
1998	1998	13.215	1.399474e+00
1999	1999	11.693	1.162232e+00
2000	2000	11.135	3.042101e+00
2001	2001	10.291	2.578441e+00
2002	2002	10.423	1.571220e+00
2003	2003	10.469	8.774404e-01
2004	2004	10.358	1.871206e-01
2005	2005	9.602	6.238745e-01
2006	2006	8.935	1.566664e+00
2007	2007	6.854	2.510666e+00
2008	2008	6.369	4.065954e+00
2009	2009	8.250	-9.173604e-07
2010	2010	8.394	1.184135e+00
2011	2011	7.781	3.416808e+00
2012	2012	7.689	2.808336e+00
2013	2013	8.193	1.478286e+00
2014	2014	8.663	1.041196e+00
2015	2015	9.376	-2.079288e-01
2016	2016	8.818	3.566845e-01
2017	2017	8.640	7.540150e-01
2018	2018	7.361	1.083821e+00
2019	2019	6.695	1.024094e+00
2020	2020	7.759	2.905546e-01
2021	2021	7.617	2.194574e+00
2022	2022	6.719	7.123508e+00
2023	2023	7.151	6.250643e+00

```

# Convertir data_FIN en un objeto de serie
# temporal (solo aplicar en caso de error) data_
<- ts(data_FIN, start = c(1969), frequency = 1

# Verificar la
# clase nuevamente
class(data_FIN)
[1] "mts"   "ts"    "matrix" "array"

```

```

# Supongamos que data_FIN es un objeto de serie temporal
time_index <- time(data_FIN)

# Encontrar la posición del año 1983
pos_1983 <- which(time_index == 1983)
print(pos_1983)
[1] 15

# Verificar el resultado
print(data_FIN[pos_1983, ])

```

country	iso2c	iso3c	year	desempleo	inflacion
1.0000	1.0000	1.0000	1974.0000	1.6100	16.9364

```

# Contrastamos cambio en 1983, corresponde a la observación 15 del
# data frame sctest(inf~ des, data=data_FIN_clean, type = "Chow",
# point = 15)

```

Chow test

```

data: inf ~ des
F = 14.735, p-value = 8.897e-06

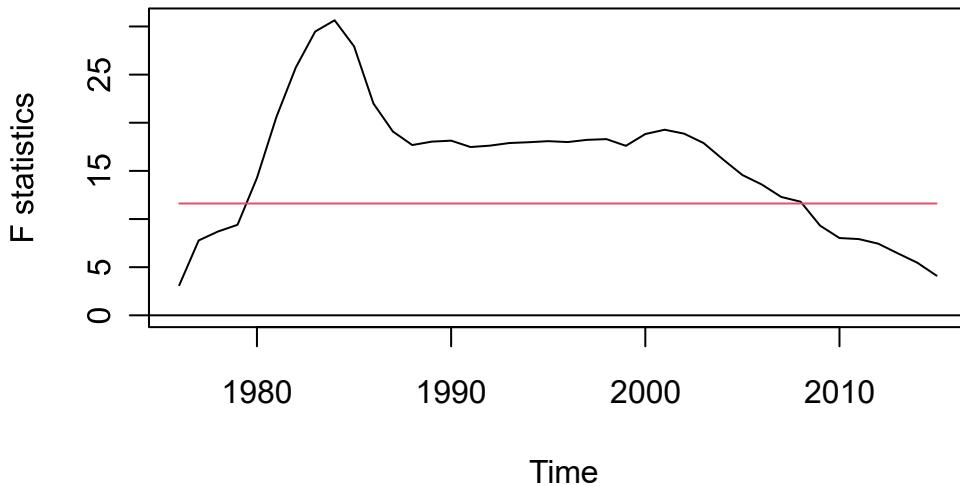
```

El valor difiere, aquí si concluimos que existe un cambio estructural, lo visualizamos mejor en el gráfico con la función fs (si existen picos evidencia cambio estructural).

```

# Con f-stats al desconocer la fecha de
# ruptura fs <- Fstats(inf~ des,
# data=data_FIN_clean) plot(fs)

```



Recapitulamos:

```
# Cargar el paquete strucchange
library(strucchange)

# Verificar la estructura de data_FIN_clean
str(data_FIN_clean)
```

```
Time-Series [1:55, 1:2] from 1969 to 2023: 2.83 1.89 2.26 2.42 2.45 1.61 2.08
3.75 6.09 7.23 - attr(*, "dimnames")=List of 2
..$ : NULL
..$ : chr [1:2] "des" "inf"
```

```
nrow(data_FIN_clean)
```

```
[1] 55
```

```
colnames(data_FIN_clean)
```

```
[1] "des" "inf"
```

```
# Verificar el índice temporal
time_index <- time(data_FIN_clean)
print(time_index[15]) # Verificar que corresponde a 1983
[1] 1983
```

```
# Aplicar el contraste de Chow
resultado <- sctest(inf ~ des, data = data_FIN_clean, type =
"Chow", point =
# Mostrar el resultado
print(resultado)
```

15)

```
Chow test

data: inf ~ des
F = 14.735, p-value = 8.897e-06
```

## 9. Estimación de la curva de Phillips aumentada con expectativas.

Aquí se estima una versión de la curva de Phillips aumentada por expectativas para el intervalo temporal más reciente: 1983-2023 (data\_FIN.2). Se queda fuera del análisis el periodo de “Gran Inflación” de los años 70 que puede distorsionar los resultados. El modelo econométrico es:

$$inf_t = \beta_0 + \beta_1 inf_{t-1} + \beta_2 dest_t + \beta_3 dest_{t-1} + \epsilon_t$$

Contrastamos la existencia de estacionariedad con el test de DFA con la ecuación constante y sin tendencia

```
#Desempleo (1983-2023)
summary(ur.df(y=data_FIN.2[,1],lags=6, type='drift',
selectlags=c("BIC")))
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

```
Call: lm(formula = z.diff ~ z.lag.1 + 1
+ z.diff.lag)
```

Residuals:

```

      Min       1Q Median       3Q      Max
-1.84778 -0.60252 -0.08811 0.66286 2.10118

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 2.06921  0.57472  3.600 0.001094 ***
z.lag.1    -0.20822  0.05678 -3.667 0.000912 ***
z.diff.lag  0.66268  0.12213  5.426 6.33e-06 ***
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' '
1

Residual standard error: 1.105 on 31 degrees of freedom
Multiple R-squared: 0.543, Adjusted R-squared: 0.5135
F-statistic: 18.41 on 2 and 31 DF, p-value: 5.363e-06

```

Value of test-statistic is: -3.6673 6.8127

Critical values for test statistics:

	1pct	5pct
10pct tau2	-3.58	-
2.93 -2.60 phil	7.06	
4.86 3.94		

```
#Inflación (1983-2023)
summary(ur.df(y=data_FIN.2[,2],lags=6, type='drift',
selectlags=c("BIC")))
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
Test regression drift
```

Call: lm(formula = z.diff ~ z.lag.1 + 1  
+ z.diff.lag)

Residuals:

Min	1Q	Median	3Q	Max
-----	----	--------	----	-----

```

-3.5560 -0.5831 -0.2737 0.3827 4.4086

Coefficients:
            Estimate Std. Error t value Pr(>|t| )
(Intercept) 0.9443     0.3648    2.588 0.0146 *
z.lag.1     -0.4873    0.1452   -3.357 0.0021 **
z.diff.lag  0.3390    0.1762    1.924 0.0636 .
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' '
1

```

Residual standard error: 1.327 on 31 degrees of freedom  
Multiple R-squared: 0.2678, Adjusted R-squared: 0.2206  
F-statistic: 5.67 on 2 and 31 DF, p-value: 0.007969

Value of test-statistic is: -3.3566 5.635

Critical values for test statistics:  
1pct 5pct  
10pct tau2 -3.58 -  
2.93 -2.60 phi1 7.06  
4.86 3.94

Resultados del contraste:

- En base al criterio BIC se selecciona el modelo con 1 retardo para las series de desempleo e inflación.
- El estadístico de DFA (tau2) es igual a -3.58 tanto para el desempleo como para la inflación
- Se rechaza la Hipótesis nula de raíz unitaria al 5% para la inflación, y al 10% para el desempleo, por lo que las dos series son estacionarias (I(0) de media constante).

Contrastando estacionariedad con la función *unitrootTest*:

```
# Desempleo (1983-2023)
unitrootTest(data_FIN.2[,1], lags = 1, type =
c("c"))
```

Title:  
Augmented Dickey-Fuller Test

Test Results:

PARAMETER:

Lag Order: 1

STATISTIC:

DF: -2.9631

P VALUE: t:

0.04718 n:

0.6487

Description:

Mon Apr 21 15:25:10 2025 by user: JM

```
# Inflación (1983-2023)
unitrootTest(data_FIN.2[,2], lags = 1, type =
c("c"))
```

Title:

Augmented Dickey-Fuller Test

Test Results:

PARAMETER:

Lag Order: 1

STATISTIC:

DF: -3.1551

P VALUE: t:

0.03041 n:

0.6243

Description:

Mon Apr 21 15:25:10 2025 by user: JM

Comprobamos que ambas series son I(0) y podemos estimar por MCO

9.2. *Estimación de la curva de Phillips aumentada con expectativas.*

La curva de Phillips aumentada con expectativas:  $\inf_t = \beta_0 + \beta_1 \inf_{t-1} + \beta_2 \des_t + \beta_3 \des_{t-1} + \epsilon_t$  es un modelo dinámico de endógena retardada.

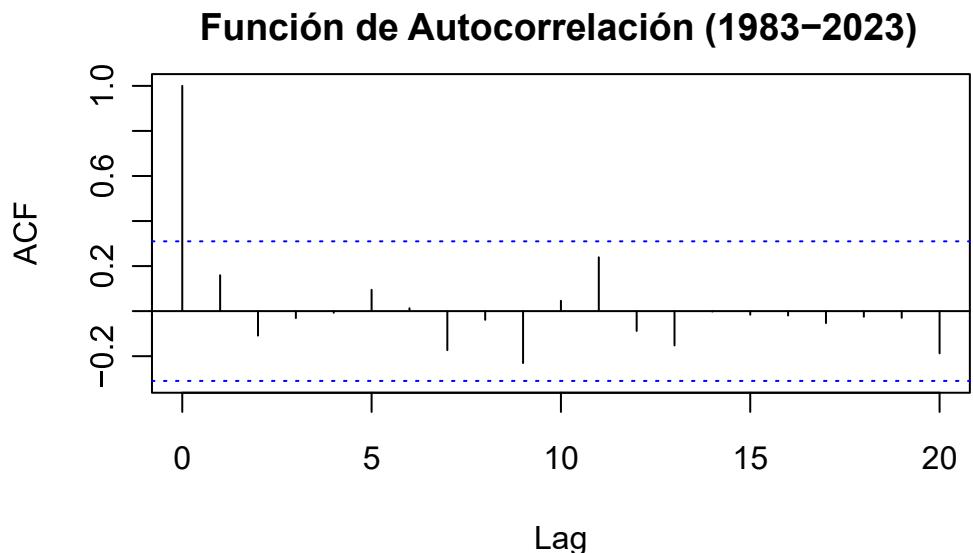
```
# Modelo dinámico (1983-2023)
```

```
modelo3 <- dynlm(inf ~ L(inf, 1) + des + L(des, 1), data =  
data_FIN.2) summary(modelo3)
```

```
Time series regression with "ts"  
data: Start = 1984, End = 2023  
  
Call: dynlm(formula = inf ~ L(inf, 1) + des + L(des, 1),  
data = data_FIN.2)  
  
Residuals:  
    Min      1Q Median      3Q     Max  
-3.0623 -0.7385 -0.1925  0.6120  4.3330  
  
Coefficients:  
            Estimate Std. Error t value Pr(>|t|)  
(Intercept) 1.8396    0.8454  2.176 0.03620 *  
L(inf, 1)   0.6811    0.1145  5.947 8.17e-07 ***  
des        -0.4149    0.1422 -2.918 0.00604 **  
L(des, 1)   0.2946    0.1538  1.915 0.06341 .  
---  
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 '  
1  
  
Residual standard error: 1.255 on 36 degrees of freedom  
Multiple R-squared: 0.6702, Adjusted R-squared: 0.6428 F-  
statistic: 24.39 on 3 and 36 DF, p-value: 8.617e-09
```

Contrastamos autocorrelación:

```
# La función de autocorrelación de los residuos del modelo3  
acf(modelo3$residuals, lag.max = 20, main = "Función de Autocorrelac  
(1983-2023)")
```



```
#Contrastes de autocorrelacion de Breusch-Godfrey en el modelo3
bgtest(modelo3,order = 1)
```

```
Breusch-Godfrey test for serial correlation of order up
to 1
```

```
data: modelo3
LM test = 1.8017, df = 1, p-value = 0.1795
```

```
bgtest(modelo3,order = 2)
```

```
Breusch-Godfrey test for serial correlation of order up
to 2
```

```
data: modelo3
LM test = 2.2626, df = 2, p-value = 0.3226
```

En el modelo con dinámica no existe evidencia de autocorrelación, los contrastes no rechazan la hipótesis nula de *no autocorrelación*. Contrastamos la existencia de heterocedasticidad. #Contraste

```
de heteroscedasticidad de Breusch-Pagan en el modelo3  
bptest(modelo3,data = data_FIN.2)
```

```
studentized Breusch-Pagan test  
  
data: modelo3  
BP = 1.0784, df = 3, p-value = 0.7823
```

No se rechaza la nula, el modelo es homocedástico. Los resultados de los contrastes de significatividad individuales en el modelo estimado muestran que todas las variables son significativas, y que el desempleo tiene un efecto contemporáneo negativo y significativo sobre la inflación. Igualmente, el modelo cumple la condición de estabilidad porque  $|\beta_1| < 1$ .

Ahora representamos en un gráfico la serie de inflación, la serie estimada y los residuos del modelo observamos que el ajuste es relativamente bueno. Vemos el efecto de la guerra de Ucrania en los residuos que toman valores más elevados y la serie estimada se ajusta peor a la serie observada, muy lógico, más siendo Finlandia frontera con Rusia (he invadido en el pasado soviético).

```
# Comprobamos si existen valores faltantes en data_FIN.2  
sum(is.na(data_FIN.2))
```

```
[1] 0
```

```
residuos<-resid(modelo3) inflacion<-  
data_FIN.2[, "inf"] inflacion.estimada<-  
fitted(modelo3)
```

Comprobación de NAs en la columna de los residuos

```
# Verificar valores faltantes en residuos  
sum(is.na(residuos))
```

```
[1] 0
```

```
# Verificar valores faltantes en inflación estimada  
sum(is.na(inflacion.estimada))
```

```
[1] 0
```

Comprobaciones antes de graficar

```
# Longitud de los vectores  
length(time(data_FIN.2)) # Índice temporal
```

```
[1] 41
```

```
length(residuos) # Residuos del modelo
```

```
[1] 40
```

```
length(inflacion) # Inflación observada
```

```
[1] 41
```

```
length(inflacion.estimada) # Inflación estimada
```

```
[1] 40
```

```
# Verificar la estructura de residuos, inflacion e  
inflacion.estimada str(residuos)  
Time-Series [1:40] from 1984 to 2023: 0.0542 -0.8917 -1.7106 0.8117  
0.8059 ... - attr(*, "names")= chr [1:40] "1984" "1985" "1986"  
"1987" ...
```

```
str(inflacion)
```

```
Time-Series [1:41] from 1983 to 2023: 8.37 7.07 5.2 2.93  
4.11 ...
```

```
str(inflacion.estimada)
```

```
Time-Series [1:40] from 1984 to 2023: 7.01 6.09 4.64 3.3  
4.28 ...
```

```
# Verificar la estructura del objeto combinado
```

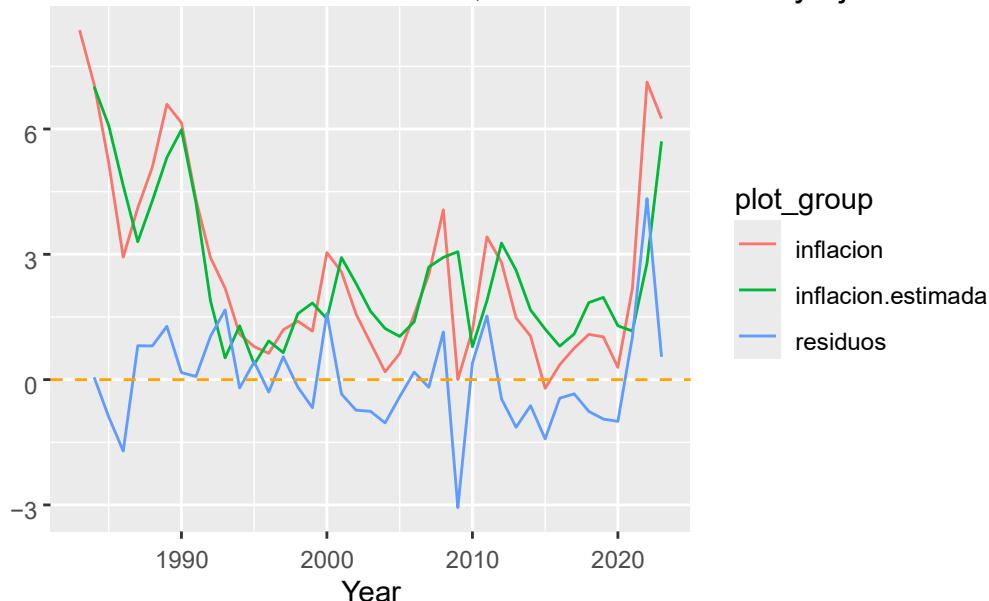
```
datos_grafico <- cbind(residuos, inflacion, inflacion.estimada)
str(datos_grafico)
```

```
Time-Series [1:41, 1:3] from 1983 to 2023: NA 0.0542 -0.8917 -1.7106 0.8117 ...
- attr(*, "dimnames")=List of 2
..$ : NULL
..$ : chr [1:3] "residuos" "inflacion"
"inflacion.estimada"
```

```
autoplot(cbind(residuos,inflacion,inflacion.estimada),
facets=FALSE) + xlab("Year") + ylab("") +geom_hline(yintercept =
0, linetype = "dashed", ggtitle("Modelo dinámico.
Residuos, valores observados y ajustados")
color = "orange")
```

Warning: Removed 2 rows containing missing values or values outside the scale range (`geom\_line()`).

### Modelo dinámico. Residuos, valores observados y ajustados



#### 9.1. Cálculo de los multiplicadores

- El multiplicador de corto plazo (multiplicador de impacto) es  $\beta_2$ . El valor estimado es:  $\hat{\beta}_2 = -0.4149$ . Es estadísticamente significativo, lo que sugiere un *tradeoff* contemporáneo entre

inflación y desempleo. Si la tasa de desempleo sube 1 punto porcentual, en promedio la tasa de inflación disminuye 0.42 puntos porcentuales ese mismo año. El mercado de trabajo es un poco menos sensible a la inflación que el de los Estados Unidos.

- El multiplicador de largo plazo es:  $\beta_2 + \beta_3$ . El valor estimado es 0.3189. Para contrastar

$$1 - \beta_1$$

si el multiplicador de largo plazo es significativo tenemos que llevar a cabo el siguiente contraste de hipótesis:

$$\left\{ \begin{array}{ll} H^0 & H : \quad \beta + \beta_3 = 0 \\ H : noH & 1 \quad 0 \end{array} \right.$$

```
# Especificamos el modelo en el que queremos hacer el contraste, la hipótesis nula y el estad linearHypothesis(modelo3,c("des+L(des, 1)=0"),test="F")
```

```
Linear hypothesis
test: des + L(des,0

Model 1: restricted model
Model 2: inf ~ L(inf, 1) + des + L(des, 1)

Res.Df  RSS Df Sum of Sq    F Pr(>F)
1     37 61.350
2     36 56.706 1      4.6443 2.9485 0.09455 .
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' '
1
```

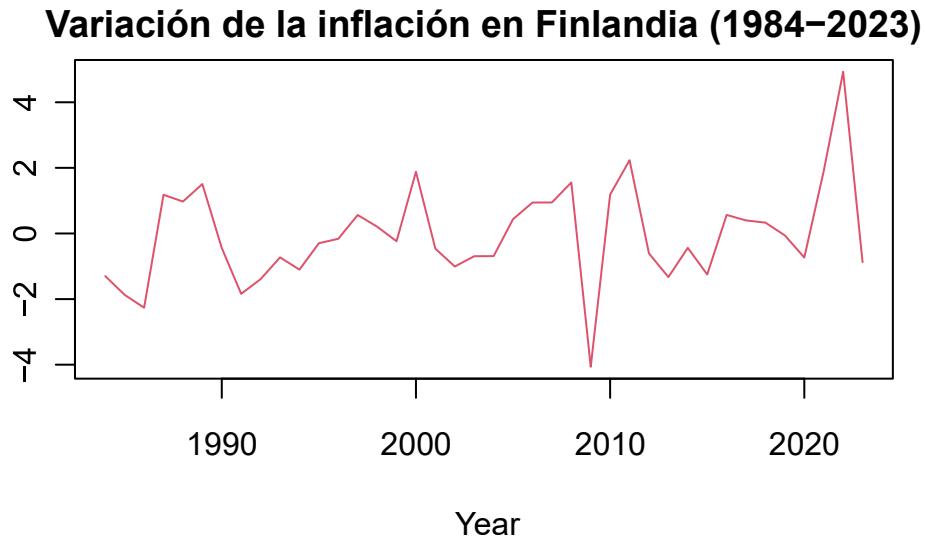
Indicandonos que para Finlandia en el largo plazo si existe una relación entre inflación y desempleo.

## 10. Estimación de la curva de Phillips aumentada con expectativas (una versión más simple).

```
#Para calcular las primeras diferencias de la inflación
dinf=diff(data_FIN.2[, "inf"])
```

```
#Para ver un gráfico
```

```
ts.plot(dinf, col=2, xlab="Year", ylab = "", main="Variación de la inflación en Finlandia (1984-2023)
```



Comprobamos que las primeras diferencias de la inflación son I(0).

```
# Contraste de raíz unitaria sobre las primeras diferencias de la inflación  
(Ecuación con con summary(ur.df(y=dinf, lags=6, type='drift',  
selectlags=c("BIC"))))
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression drift

```
Call: lm(formula = z.diff ~ z.lag.1 + 1  
+ z.diff.lag)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.8354	-0.6829	-0.2664	0.5474	4.5305

Coefficients:

```

            Estimate Std. Error t value Pr(>|t| )
(Intercept) -0.0296   0.2621 -0.113   0.911
z.lag.1     -1.2694   0.2579 -4.922 2.9e-05 ***
z.diff.lag   0.3568   0.2109  1.692   0.101
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' '
1

Residual standard error: 1.502 on 30 degrees of freedom
Multiple R-squared: 0.5184, Adjusted R-squared: 0.4863
F-statistic: 16.15 on 2 and 30 DF, p-value: 1.739e-05

```

Value of test-statistic is: -4.9223 12.1205

Critical values for test statistics:

	1pct	5pct
10pct tau2	-3.58	-
2.93	-2.60	phi1 7.06
4.86	3.94	

A continuación, estimamos el modelo

```
#Estimamos el modelo y guardamos los resultados en un objeto
llamado modelo4 modelo4<-dynlm(dinf~des+L(des,1),
data=data_FIN.2) summary(modelo4)
```

```

Time series regression with "ts"
data: Start = 1984, End = 2023

Call: dynlm(formula = dinf ~ des + L(des, 1), data
= data_FIN.2)

Residuals:
    Min      1Q  Median      3Q      Max 
-3.1325 -0.7714 -0.1903  0.7107  4.5042 

Coefficients:
            Estimate Std. Error t value
Pr(>|t|) (Intercept) 0.06064      0.60201

```

```

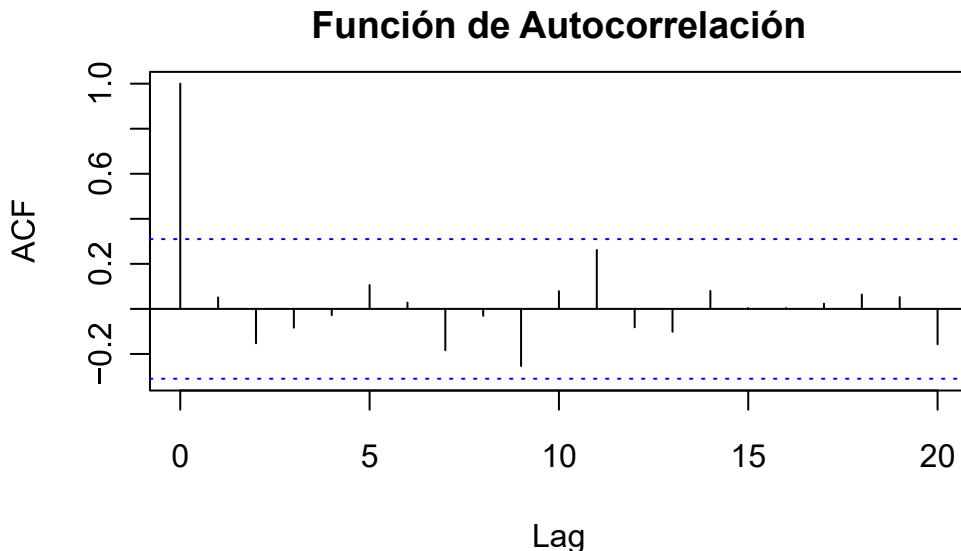
0.101 0.92031 des      -0.49341   0.15156 -
3.255 0.00242 ** L(des, 1)  0.48305
0.15017    3.217 0.00269 **

---
Signif. codes: 0 '****' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' '
1

Residual standard error: 1.365 on 37 degrees of freedom
Multiple R-squared: 0.2285, Adjusted R-squared: 0.1868 F-
statistic: 5.478 on 2 and 37 DF, p-value: 0.008241

```

```
# La función de autocorrelación de los residuos del modelo4
acf(modelo4$residuals, lag.max = 20, main = "Función de
Autocorrelación")
```



```
#Contrastes de autocorrelacion de Breusch-Godfrey en el modelo4
bgtest(modelo4,order = 1)
```

```
Breusch-Godfrey test for serial correlation of order up
to 1

data: modelo4
```

```
LM test = 0.10444, df = 1, p-value = 0.7466
```

```
bgttest(modelo4,order = 2)
```

```
Breusch-Godfrey test for serial correlation of order up  
to 2  
data: modelo4  
LM test = 1.575, df = 2, p-value = 0.455
```

```
#Contraste de heteroscedasticidad de Breusch-Pagan en el modelo4  
bptest(modelo4)
```

```
studentized Breusch-Pagan test  
  
data: modelo4  
BP = 1.1104, df = 2, p-value = 0.574
```

Calculamos los multiplicadores:

- El multiplicador de corto plazo (multiplicador de impacto) es  $\beta_1$ . El valor estimado es:  $\hat{\beta}_1 = -0.4934$ . El multiplicador de corto plazo es estadísticamente significativo, lo que sugiere un *tradeoff* contemporáneo entre la *variación* de la inflación y el desempleo.
- El multiplicador de largo plazo es:  $\beta_1 + \beta_2$ . El valor estimado es -0.01036. Para contrastar si el multiplicador de largo plazo es significativo tenemos que llevar a cabo el siguiente contraste de hipótesis:

$$\begin{array}{cc} & H : \beta + \beta_2 = 0 \\ \begin{matrix} 1 & 0 \end{matrix} & \left\{ \begin{matrix} H^0 & H^1 \\ H : noH \end{matrix} \right. \end{array}$$

```
# Especificamos el modelo en el que queremos hacer el contraste, la hipótesis  
nula y el estad linearHypothesis(modelo4,c("des+L(des, 1)=0"),test="F")
```

```
Linear hypothesis  
test: des + L(des,0
```

```
Model 1: restricted model
```

Model 2: dinf ~ des + L(des, 1)

Res.Df	RSS	Df	Sum of SqF	Pr(>F)	1
38	68.967	2	37 68.916	1 0.050518	0.0271 0.8701

El estadístico F vale 0.0271 y tiene un p-valor=0.8701, por lo que no se rechaza la nula, mostrando que a la largo plazo no hay relación entre la variación de la inflación y el desempleo.